МИНОБРНАУКИ РОССИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НИЖЕГОРОДСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ ИМ. Р.Е. АЛЕКСЕЕВА»



Институт радиоэлектроники и информационных технологий
Кафедра «Компьютерные технологии в проектировании и производстве»

Отчет по лабораторной работе №1

Исследование энтропии, избыточности алфавитных источников и эффективности сжатия текстовых данных

по дисциплине «Основы радиоэлектроники и связи»

СТУДЕНТ

	Стенин Д. Ю., Разумов В. А.
(подпись)	*(фамилия, и., о.)*
	23-ТР
(дата)	*(группа или шифр)*

ПРЕПОДАВАТЕЛЬ

	Штанюк А. А.
(подпись)	*(фамилия, и., о.)*
(дата)	

Комментарии	*Дата сдачи*	*Дата проверки*	*Отметка о выполнении*

Нижний Новгород 2026 г.

Копировал Формат А4

Содержание

Введение 3
1 Теоретические основы 4
1.1 Модель дискретного источника сообщений 4
1.2 Информационные характеристики источника по Шеннону 4
1.3 Оценка эффективности сжатия данных 5
2 Выполнение экспериментальной части 7
2.1 Задание 1. Исследование равновероятного источника и моноалфавитного шифрования 7
2.1.1 Генерация псевдослучайной последовательности и расчет параметров 7
2.1.2 Исследование влияния шифра Цезаря на статистические характеристики 8
2.1.3 Оценка степени сжатия синтетического файла 9
2.2 Задание 2. Исследование англоязычного естественного текста 10
2.2.1 Статистический анализ текста романа «Война и мир» на английском языке 10
2.2.2 Расчет энтропии, избыточности и оценка степени сжатия 11
2.2.3 Сравнительный анализ с синтетическим источником 11
2.3 Задание 3. Исследование русскоязычного естественного текста 12
2.3.1 Частотный анализ букв русского алфавита 12
2.3.2 Определение информационных характеристик и сжатие данных ... 14
2.3.3 Сопоставление характеристик русского и английского текстов 14
3 Сводный анализ результатов и инженерные выводы 15
Заключение 16

Введение

В цифровых каналах связи и радиоэлектронных средствах (РЭС) передаваемые сообщения обычно обладают статистической избыточностью: частоты символов алфавита неодинаковы, а в словах присутствуют устойчивые сочетания букв. Устранение этой избыточности с помощью сжатия позволяет уменьшить число передаваемых бит, снизить время передачи по радиоканалу и сэкономить буферную память приёмопередатчиков.

При проектировании тракта передачи важен порядок этапов обработки: сжатие данных должно выполняться до шифрования. Любой стойкий шифр делает статистику выходного потока близкой к равномерному шуму, после чего алгоритмы сжатия уже не могут найти закономерности и уменьшить объём.

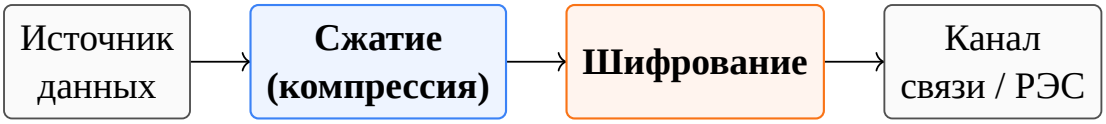


Рисунок 1 — Последовательность предварительной обработки данных в тракте передачи

Цель работы: экспериментально рассчитать энтропию и избыточность дискретных источников (псевдослучайной последовательности и текстов на английском и русском языках), проверить устойчивость статистических характеристик при моноалфавитном шифровании и сопоставить теоретические оценки с реальным сжатием архиватором Deflate.

Задачи работы:

1. сгенерировать псевдослучайную последовательность латинских букв (`'a'–'z'`) в кодировке ASCII объёмом 100 000 символов (равновероятный источник);
2. рассчитать для неё энтропию, объём информации и относительную избыточность;
3. зашифровать полученную последовательность шифром Цезаря и проверить сохранение энтропии и частот символов;
4. сжать исходный и зашифрованный файлы алгоритмом Deflate и сравнить коэффициенты сжатия;
5. выполнить частотный анализ текста романа «Война и мир» на английском языке (ASCII), рассчитать энтропию, избыточность и коэффициент сжатия;
6. провести аналогичные расчёты для русского текста романа в кодировке UTF-8;
7. сравнить полученные характеристики естественных текстов со случайным источником и объяснить различия в степени сжатия.

1 Теоретические основы

1.1 Модель дискретного источника сообщений

Дискретный источник информации задаётся первичным алфавитом $A = \{a_1, a_2, ..., a_m\}$ объёмом m и множеством вероятностей появления символов $P = \{p(a_1), p(a_2), ..., p(a_m)\}$. Поскольку появление одного из символов является достоверным событием, выполняется условие нормировки:

$$\sum_{i=1}^{m} p(a_i) = 1. \tag{1.1}$$

Если выбор каждого очередного символа не зависит от предыдущих, источник называют дискретным источником без памяти.

Собственная информация, переносимая символом a_i, измеряется в битах:

$$I(a_i) = -\log_2 p(a_i) = \log_2 \frac{1}{p(a_i)}. \tag{1.2}$$

1.2 Информационные характеристики источника по Шеннону

Энтропия источника $H(A)$ определяется как математическое ожидание собственной информации символов и показывает среднюю неопределённость, приходящуюся на один символ:

$$H(A) = -\sum_{i=1}^{m} p(a_i) \log_2 p(a_i) \quad [\text{бит/символ}]. \tag{1.3}$$

Максимальное значение энтропия принимает при равновероятном появлении всех букв алфавита ($p(a_i) = \frac{1}{m}$):

$$H_{\max} = \log_2 m. \tag{1.4}$$

Разность между максимальной и реальной энтропией задаёт абсолютную избыточность источника D:

$$D = H_{\max} - H(A) \quad [\text{бит/символ}]. \tag{1.5}$$

Относительная избыточность R показывает долю избыточной информации в сообщении:

$$R = \frac{D}{H_{\max}} = 1 - \frac{H(A)}{\log_2 m}. \tag{1.6}$$

Для равновероятного источника $R = 0$. Чем сильнее различаются вероятности букв, тем выше избыточность R.

Информационный объём сообщения длиной N символов равен:

$$I_{\text{общ}} = N \cdot H(A) \quad [\text{бит}]. \tag{1.7}$$

В реальных компьютерах каждый символ сохраняется фиксированным числом двоичных разрядов: в ASCII это 8 бит (1 байт), в UTF-8 для кириллицы — 16 бит (2 байта). Из-за этого физический размер файла $V_{\text{байт}}$ почти всегда заметно превышает его информационный объём $I_{\text{общ}}$.

1.3 Оценка эффективности сжатия данных

Цель алгоритмов сжатия без потерь — устранить избыточность R. Согласно теореме Шеннона для канала без шума, средняя длина кодового слова $\overline{L}$ не может быть меньше энтропии источника:

$$\overline{L} \geq H(A). \tag{1.8}$$

Эффективность сжатия файла оценивается коэффициентом сжатия $K_{\text{сжат}}$ и относительной степенью сжатия C_{ratio}:

$$K_{\text{сжат}} = \frac{V_{\text{исх}}}{V_{\text{сжат}}}, \tag{1.9}$$

$$C_{\text{ratio}} = \left(1 - \frac{V_{\text{сжат}}}{V_{\text{исх}}}\right) \cdot 100\%. \tag{1.10}$$

В таблице 1.1 приведены теоретические оценки энтропии и ожидаемые пределы сжатия для исследуемых источников с учётом формата их хранения.

Таблица 1.1 — Теоретические характеристики исследуемых моделей источников

Тип источника	**Алфавит m**	**Энтропия H**	**Избыточность R**	**Ожидаемое сжатие Deflate**
Случайный (ASCII)	26	$\log_2 26 \approx 4.70$	$\approx 0\%$	$K \approx 1.6 - 1.7$ (упаковка $8 \to 5$ бит)
Шифр Цезаря (ASCII)	26	$\log_2 26 \approx 4.70$	$\approx 0\%$	$K \approx 1.6 - 1.7$ (инвариантно)
Английский (ASCII)	26	$\approx 4.1 - 4.2$	$10 - 15\%$	$K > 2.5$ (LZ77 + Хаффман)
Русский (UTF-8)	32	$\approx 4.3 - 4.5$	$10 - 15\%$	$K > 3.5$ (UTF-8 + LZ77)

При анализе сжатия $K_{\text{сжат}}$ важно учитывать разницу между теоретической моделью источника и реальным форматом файла на диске. В теории равновероятный шум несжимаем ($K = 1$), если каждый символ уже закодирован минимальной дробной разрядностью $\log_2 26 \approx 4.70$ бит. На практике же в файле ASCII под каждый символ отводится целый байт (8 бит).

Поэтому даже для некоррелированного случайного шума архиватор даёт сжатие за счёт упаковки байтов кодом Хаффмана:

$$K_{\text{max, ASCII}} = \frac{8}{H_{\text{max}}} = \frac{8}{4.7004} \approx 1.702. \tag{1.11}$$

В текстах на естественных языках к этой байтовой упаковке добавляется алгоритм LZ77, который находит повторяющиеся слова и фразы, поэтому коэффициент возрастает до $K_{\text{сжат}} > 2.5$. Для русского текста в UTF-8 каждый символ занимает 2 байта (16 бит), из-за чего удаление двухбайтового контейнера вместе с поиском повторов даёт наибольшее сжатие — $K_{\text{сжат}} > 3.5$.

2 Выполнение экспериментальной части

2.1 Задание 1. Исследование равновероятного источника и моноалфавитного шифрования

2.1.1 Генерация псевдослучайной последовательности и расчет параметров

Для моделирования равновероятного источника сгенерирован файл объёмом $N = 100\,000$ символов. Использовался алфавит из 26 строчных латинских букв (`'a'–'z'`) в кодировке ASCII. Расчёт частот, энтропии и избыточности выполнен на Python (см. листинг 2.1).

```python
from collections import Counter
import math
import random
import string

def generate_uniform_text(
    n: int = 100_000,
    alphabet: str = string.ascii_lowercase,
    seed: int | None = 260,
) -> str:
    if seed is not None:
        random.seed(seed)

    return "".join(random.choices(alphabet, k=n))


def compute_metrics(
    text: str, m: int = 26
) -> tuple[Counter, float, float, float, float]:
    n = len(text)
    if n == 0:
        return Counter(), 0.0, math.log2(m) if m > 0 else 0.0, 0.0, 0.0

    counts = Counter(text)

    h = -sum(
        (cnt / n) * math.log2(cnt / n) for cnt in counts.values() if cnt > 0
    )
    h_max = math.log2(m)

    redundancy = (1 - h / h_max) * 100.0 if h_max > 0 else 0.0
    total_info = n * h

    return counts, h, h_max, redundancy, total_info
```

Листинг 2.1 — Генерация равномерной псевдослучайной последовательности и расчет параметров источника

Теоретическая максимальная энтропия для алфавита мощностью $m = 26$ составляет:

$$H_{\max} = \log_2(26) \approx 4.7004 \quad [\text{бит/символ}]. \tag{2.1}$$

По результатам расчёта энтропия сформированного файла составила $H_1 = 4.7001$ бит/символ (теоретический максимум $H_{\max} = 4.7004$ бит/символ). Относительная избыточность получилась равной $R_1 \approx 0.007\%$, что на практике соответствует равномерному распределению без корреляции между символами.

2.1.2 Исследование влияния шифра Цезаря на статистические характеристики

Для проверки того, как моноалфавитная замена влияет на статистику, исходный текст был зашифрован шифром Цезаря со сдвигом $k = 3$ (листинг 2.2).

```python
def caesar_cipher(text: str, shift: int = 3) -> str:
    res = []
    for char in text:
        if "a" <= char <= "z":
            shifted = chr((ord(char) - ord("a") + shift) % 26 + ord("a"))
            res.append(shifted)
        else:
            res.append(char)

    return "".join(res)
```

Листинг 2.2 — Реализация моноалфавитного шифра Цезаря для латинского алфавита

Распределение частот появления символов до и после шифрования показано на рисунке 2.1.

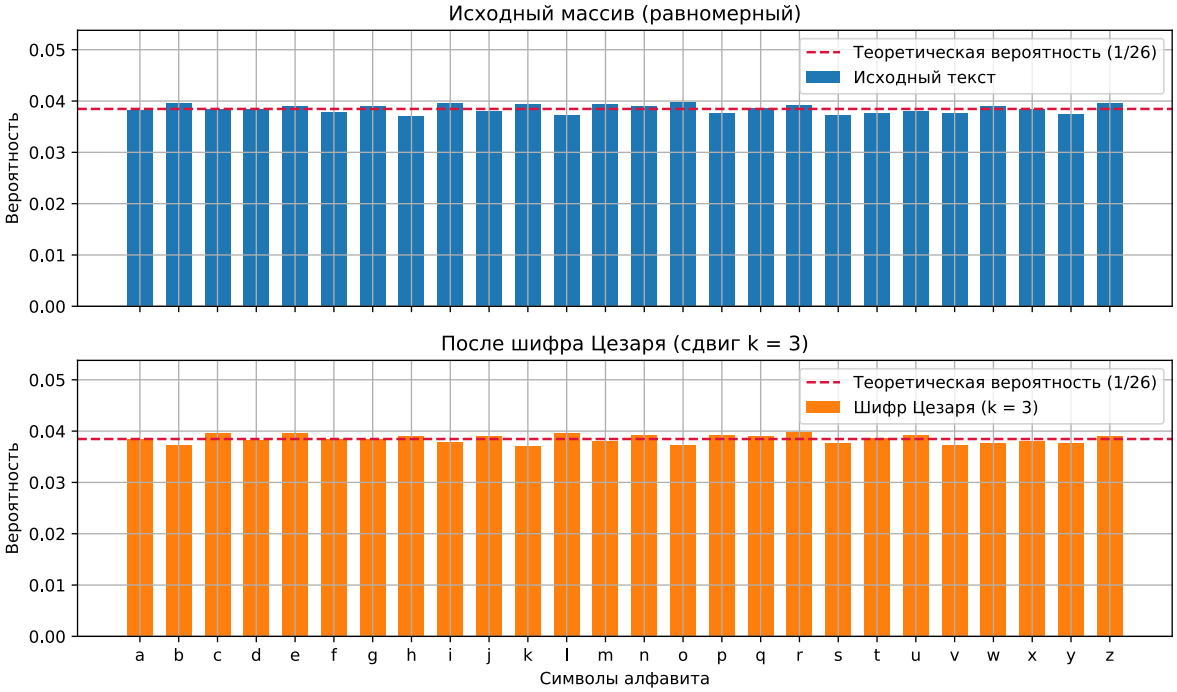


Рисунок 2.1 — Распределение вероятностей появления символов в псевдослучайном файле до и после применения шифра Цезаря ($k = 3$)

Как видно из рисунка 2.1, шифрование привело лишь к циклическому сдвигу гистограммы вправо на 3 позиции. Сами значения вероятностей не изменились, они просто перешли к другим буквам.

2.1.3 Оценка степени сжатия синтетического файла

Исходный и зашифрованный файлы были сохранены на диск в кодировке ASCII (размер каждого $100\,000$ байт) и упакованы алгоритмом Deflate (модуль `zipfile`, сжатие со стандартными параметрами).

Сводные результаты расчётов и архивации приведены в таблице 2.1.

Таблица 2.1 — Информационные параметры и результаты сжатия случайного файла до и после шифрования

Состояние массива	H, бит/симв.	$H_{\max}$, бит	R, %	Размер, байт	ZIP, байт	$K_{\text{сжат}}$
Исходный случайный	4.7001	4.7004	0.007	100 000	63 546	1.574
Шифр Цезаря ($k = 3$)	4.7001	4.7004	0.007	100 000	63 560	1.573

Архивация Deflate уменьшила размер обоих файлов со $100\,000$ примерно до $63\,550$ байт ($K_{\text{сжат}} \approx 1.57$). Этот выигрыш получен исключительно за счёт устранения лишних 3 бит в каждом байте ASCII (переход от 8 бит к коду Хаффмана длиной ≈ 5 бит):

$$V_{\min} = \frac{N \cdot H}{8} = \frac{100\,000 \cdot 4.7001}{8} \approx 58\,751 \quad [\text{байт}], \tag{2.2}$$

что даёт предел $K_{\max} = 100\,\frac{000}{58}\,751 \approx 1.702$. Архиватор приблизился к этой границе ($63\,546$ байт с учётом служебных заголовков ZIP). Словарный алгоритм LZ77 в данном случае совпадений не нашёл, поскольку в случайном шуме нет повторяющихся цепочек символов.

Поскольку шифр Цезаря сохраняет исходный набор частот символов, коэффициент сжатия зашифрованного файла остался практически тем же (1.573 против 1.574).

2.2 Задание 2. Исследование англоязычного естественного текста

2.2.1 Статистический анализ текста романа «Война и мир» на английском языке

Для анализа естественного языка взят текст романа «Война и мир» на английском языке в кодировке ASCII. В отличие от искусственного шума, буквы в реальной речи встречаются с разной частотой, а между символами есть контекстная связь.

Перед расчётами текст очистили от знаков препинания, цифр и пробелов, оставив только 26 строчных букв латиницы (листинг 2.3).

```python
from collections import Counter
import math


def analyze_natural_text(
    filepath: Path | str, m: int = 26
) -> tuple[dict[str, float], float, float, float, float, int]:
    with open(filepath, "r", encoding="ascii", errors="ignore") as f:
        raw_text = f.read()

    filtered = [ch.lower() for ch in raw_text if "a" <= ch.lower() <= "z"]

    n = len(filtered)
    counts = Counter(filtered)
    probs = {ch: cnt / n for ch, cnt in counts.items()}

    h = -sum(p * math.log2(p) for p in probs.values() if p > 0)
    h_max = math.log2(m)

    redundancy = (1 - h / h_max) * 100.0 if h_max > 0 else 0.0
    total_info = n * h

    return probs, h, h_max, redundancy, total_info, n
```

Листинг 2.3 — Функция статистического анализа естественного текста на Python

Распределение эмпирических вероятностей букв английского алфавита приведено на рисунке 2.2.

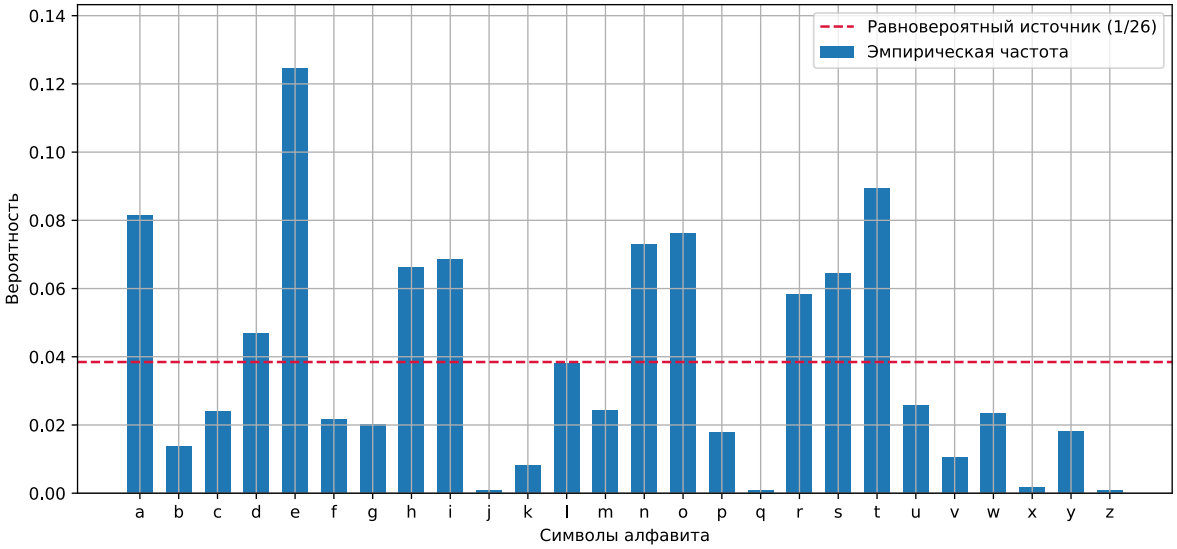


Рисунок 2.2 — Распределение частот появления букв английского алфавита в исследуемом тексте

Гистограмма на рисунке 2.2 показывает сильную неравномерность: чаще всего встречаются буквы e ($p \approx 0.125$), t ($p \approx 0.089$), a ($p \approx 0.081$), o ($p \approx 0.076$), а редкие символы q, x, z появляются с вероятностью менее 0.002.

2.2.2 Расчет энтропии, избыточности и оценка степени сжатия

По выборке объёмом $N = 2\,512\,966$ букв рассчитаны информационные характеристики. Полученная энтропия составила:

$$H_{\text{en}} = 4.1653 \quad [\text{бит/символ}]. \tag{2.3}$$

При $m = 26$ теоретический максимум равен $H_{\max} = \log_2(26) \approx 4.7004$ бит. Избыточность первого порядка составила:

$$R_{\text{en}} = \left(1 - \frac{4.1653}{4.7004}\right) \cdot 100\% \approx 11.38\%. \tag{2.4}$$

Исходный текстовый файл романа сжат алгоритмом Deflate. Сводные параметры приведены в таблице 2.2.

Таблица 2.2 — Информационные параметры и показатели сжатия англоязычного текста

Параметр	H, бит/симв.	$H_{\max}$, бит	R, %	Размер, байт	ZIP, байт	$K_{\text{сжат}}$
Текст «Война и мир» (EN)	4.1653	4.7004	11.38	3 202 941	1 189 406	2.693

2.2.3 Сравнительный анализ с синтетическим источником

Сравнение с результатами первого задания (таблица 2.1):

1. **Энтропия и избыточность.** Энтропия английского текста ($H_{\text{en}} = 4.1653$ бит/символ) на 0.535 бит ниже предельной (4.7004 бит/символ), из-за чего избыточность первого порядка составляет $R_{\text{en}} \approx 11.38\%$. У случайного источника избыточность практически отсутствовала ($R_1 \approx 0.007\%$).
2. **Степень сжатия.** Коэффициент сжатия романа составил $K_{\text{сжат}} = 2.693$ против 1.574 для случайного файла.
3. **Роль контекста и словаря.** Теоретический предел объёма при учёте только посимвольных вероятностей равен:

$$V_{\text{теор}} = \frac{N \cdot H_{\text{en}}}{8} = \frac{2\,512\,966 \cdot 4.1653}{8} \approx 1\,308\,408 \quad [\text{байт}]. \tag{2.5}$$

Реальный архив получился меньше — $1\,189\,406$ байт ($K = 2.693$ против теоретического предела первого порядка $K_{\max} \approx 2.448$). Это объясняется тем, что реальный текст содержит взаимосвязи между буквами (слова, приставки, окончания). Алгоритм LZ77 заменяет повторяющиеся цепочки символов короткими ссылками, сжимая текст сильнее, чем допускает модель без памяти.

2.3 Задание 3. Исследование русскоязычного естественного текста

2.3.1 Частотный анализ букв русского алфавита

Для исследования кириллического текста взят русский вариант «Войны и мира» в кодировке UTF-8, где каждый русский символ занимает 2 байта.

Перед обработкой из текста удалили пунктуацию, цифры и пробелы, привели все буквы к нижнему регистру, а букву «ё» заменили на «е». Итоговая мощность алфавита составила $m = 32$ буквы (листинг 2.4).

```python
from collections import Counter
import math


def analyze_russian_text(
    filepath: Path | str, m: int = 32
) -> tuple[dict[str, float], float, float, float, float, int]:
    with open(filepath, "r", encoding="utf-8", errors="ignore") as f:
        raw_text = f.read()

    cleaned = raw_text.lower().replace("ё", "е")
    filtered = [ch for ch in cleaned if "а" <= ch <= "я"]

    n = len(filtered)
    counts = Counter(filtered)
    probs = {ch: cnt / n for ch, cnt in counts.items()}

    h = -sum(p * math.log2(p) for p in probs.values() if p > 0)
    h_max = math.log2(m)

    redundancy = (1 - h / h_max) * 100.0 if h_max > 0 else 0.0
    total_info = n * h

    return probs, h, h_max, redundancy, total_info, n
```

Листинг 2.4 — Функция статистического анализа русскоязычного текста на Python

Графическое распределение вероятностей появления букв русского алфавита в исследуемом массиве представлено на рисунке 2.3.

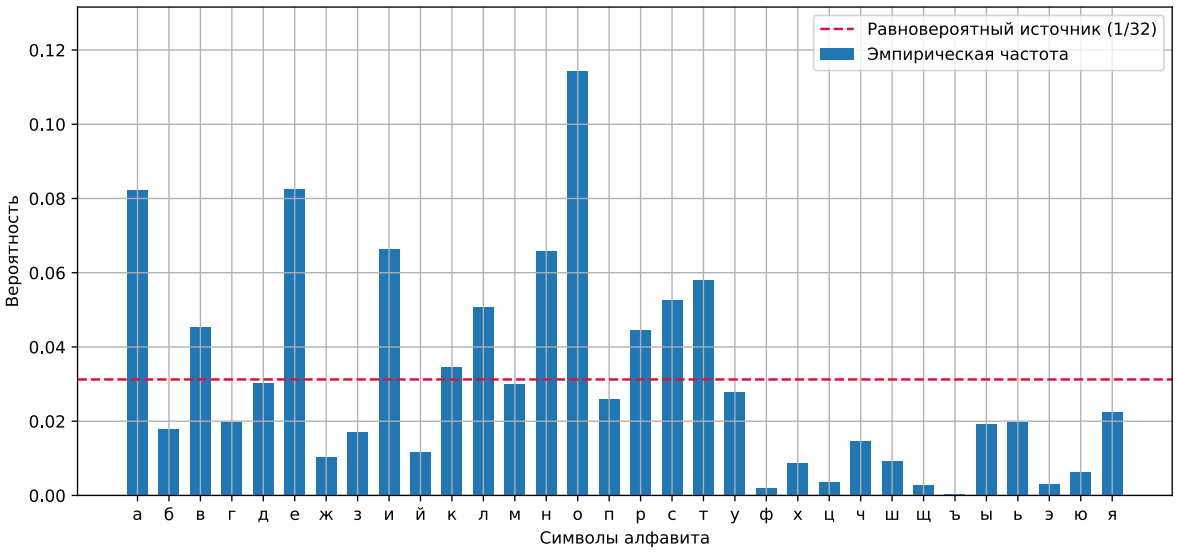


Рисунок 2.3 — Частотное распределение букв русского алфавита в тексте произведения

Гистограмма на рисунке 2.3 отражает типичное для русского языка распределение: чаще всего встречаются гласные о ($p \approx 0.114$), е ($p \approx 0.082$), а ($p \approx 0.082$) и согласные и, н, т. Реже всего появляются буквы ф ($p \approx 0.002$), э ($p \approx 0.003$) и ъ ($p < 0.001$).

2.3.2 Определение информационных характеристик и сжатие данных

Объём исследованной выборки составил $N = 1\,485\,071$ символ. Предельная энтропия для алфавита из 32 букв равна:

$$H_{\max} = \log_2(32) = 5.0000 \quad [\text{бит/символ}]. \tag{2.6}$$

Рассчитанная энтропия первого порядка составила:

$$H_{\text{ru}} = 4.4666 \quad [\text{бит/символ}]. \tag{2.7}$$

Относительная избыточность русского алфавита:

$$R_{\text{ru}} = \left(1 - \frac{4.4666}{5.0000}\right) \cdot 100\% \approx 10.67\%. \tag{2.8}$$

Файл романа в исходной кодировке UTF-8 сжали архиватором Deflate (ZIP). Параметры приведены в таблице 2.3.

Таблица 2.3 — Информационные параметры и результаты архивации русскоязычного текста

Параметр	H, бит/симв.	$H_{\max}$, бит	R, %	Размер, байт	ZIP, байт	$K_{\text{сжат}}$
Текст «Война и мир» (RU)	4.4666	5.0000	10.67	3 386 080	891 379	3.799

2.3.3 Сопоставление характеристик русского и английского текстов

Сравнение данных из таблицы 2.2 и таблицы 2.3:

1. **Энтропия алфавита.** У русского текста энтропия выше ($H_{\text{ru}} = 4.4666$ бит против $H_{\text{en}} = 4.1653$ бит), так как русский алфавит шире ($m = 32$ против $m = 26$).
2. **Избыточность.** Избыточность первого порядка у обоих языков оказалась схожей: 10.67% для русского и 11.38% для английского.
3. **Степень сжатия.** Русский файл сжался заметно сильнее ($K_{\text{сжат}} = 3.799$ против 2.693). В русском тексте архиватор устраняет не только контекстную избыточность языка (LZ77), но и двухбайтовый формат UTF-8, в котором на каждый символ тратится 16 бит при энтропии менее 4.5 бит.

Таким образом, для русскоязычных сообщений в каналах связи сжатие позволяет сократить объём почти в 4 раза ($K_{\text{сжат}} \approx 3.8$).

3 Сводный анализ результатов и инженерные выводы

В таблице 3.1 сведены результаты расчётов энтропии, теоретических пределов, избыточности и коэффициентов сжатия для всех исследованных источников.

Таблица 3.1 — Сводные параметры исследованных источников сообщений и результаты компрессии данных

Источник данных	m	N, симв.	H, бит	$H_{\max}$, бит	R, %	Исходн., Б	ZIP, Б	$K_{\text{сжат}}$	C_{ratio}, %
Равновероятный (ASCII)	26	100 000	4.7001	4.7004	0.007	100 000	63 546	1.574	36.45
Шифр Цезаря ($k = 3$)	26	100 000	4.7001	4.7004	0.007	100 000	63 560	1.573	36.44
Английский (ASCII)	26	2 512 966	4.1653	4.7004	11.38	3 202 941	1 189 406	2.693	62.86
Русский (UTF-8)	32	1 485 071	4.4666	5.0000	10.67	3 386 080	891 379	3.799	73.67

Анализ сводных данных позволяет сделать следующие выводы:

1. **Инвариантность метрик при моноалфавитной замене.** Шифр Цезаря ($k = 3$) не меняет ни энтропию ($H = 4.7001$ бит/символ), ни избыточность ($R \approx 0.007\%$), ни коэффициент сжатия ($K_{\text{сжат}} \approx 1.57$). Частоты символов лишь циклически смещаются по алфавиту. По этой причине простые моноалфавитные шифры не защищают от частотного анализа;
2. **Механизмы работы алгоритма сжатия:**
   - в случайном файле ASCII сжатие ($K_{\text{сжат}} = 1.574$) достигается только за счёт кодирования Хаффмана (упаковка 8 бит байта в ≈ 5 бит кода). Словарный поиск LZ77 здесь не работает из-за отсутствия повторяющихся цепочек;
   - в естественных текстах коэффициент значительно выше (2.693 для английского и 3.799 для русского языка), так как алгоритм LZ77 находит и заменяет ссылками частые слова и устойчивые словосочетания;
3. **Влияние формата файла (ASCII и UTF-8).** Наибольший коэффициент сжатия у русского текста ($K_{\text{сжат}} = 3.799$, $C_{\text{ratio}} = 73.67\%$) обусловлен сочетанием лексических повторов языка и устранением неэффективности UTF-8, где каждый русский символ занимает 16 бит при энтропии менее 4.5 бит;
4. **Порядок обработки в приёмопередающих трактах.** Сжатие сообщений необходимо производить строго до их шифрования. После качественного шифрования поток превращается в псевдослучайную последовательность, и словарные алгоритмы сжатия перестают давать выигрыш по объёму.

Заключение

В ходе выполнения лабораторной работы были экспериментально исследованы энтропия и избыточность псевдослучайного шума и естественных текстов на английском и русском языках, оценено влияние шифра Цезаря на распределение частот символов и сопоставлена теоретическая избыточность со степенью сжатия архиватором Deflate.

По результатам работы сформулированы следующие выводы:

1. Моноалфавитный шифр Цезаря сохраняет энтропию (4.7001 бит/символ) и частотный состав алфавита неизменными (таблица 2.1), выполняя лишь циклическую перестановку букв, поэтому он легко раскрывается методом частотного анализа;
2. Сжатие случайного ASCII-файла ($K_{\text{сжат}} = 1.574$) обусловлено исключительно устранением избыточности 8-битного байта кодером Хаффмана. В реальных текстах сжатие существенно выше (2.693 для английского и 3.799 для русского языка) благодаря словарному алгоритму LZ77, устраняющему контекстные связи между буквами и словами;
3. Максимальный выигрыш при сжатии русского текста ($K_{\text{сжат}} = 3.799$) достигается за счёт одновременного устранения контекстной избыточности речи и двухбайтового представления символов в UTF-8;
4. В трактах передачи данных радиоэлектронных систем архивацию необходимо выполнять строго перед шифрованием, поскольку зашифрованный трафик теряет контекстную избыточность и не поддаётся сжатию.